

Table des Matières

Chapitre 1 : Introduction Générale.....	5
1. Introduction	5
2. Contexte Général.....	6
3. Problématique.....	6
4. Objectifs du Projet	7
4.1. Objectif Principal	7
4.2. Objectifs Spécifiques	8
5. Organisation du Rapport	8
6. Conclusion	9
Chapitre 2 : État de l'Art.....	10
1. Introduction	10
2. Le Mélanome : Aspects Médicaux	10
2.1. Définition et Épidémiologie.....	10
2.2. Diagnostic Clinique Traditionnel	10
3. Intelligence Artificielle en Dermatologie	10
3.1. Premiers Travaux sur la Classification de Lésions	10
3.2. Émergence du Deep Learning	10
3.3. Travaux sur le Dataset HAM10000	10
4. Comparaison des Approches CNN.....	10
4.1. CNN Entraîné from Scratch.....	10
4.2. Transfer Learning.....	11
5. Positionnement de Notre Travail.....	11
6. Conclusion	11
Chapitre 3 : Dataset et Analyse Exploratoire	12
1. Introduction	12
2. Présentation du Dataset HAM10000	12
2.1. Origine et Description	12
2.2. Les 7 Classes de Lésions	14
2.3. Données Tabulaires Disponibles.....	16
3. Analyse Exploratoire des Données (EDA)	18
3.1. Distribution des Classes	18
3.2. Analyse des Métadonnées Tabulaires	21
3.3. Valeurs Manquantes.....	25
4. Biais et Limitations du Dataset.....	27
4.1. Biais Démographique — Phototypes de Fitzpatrick	28
4.2. Biais Géographique et Conditions d'Acquisition	28

4.3. Déséquilibre des Classes Revisité sous l'Angle du Biais	28
4.4. Limitation des Métadonnées Cliniques	29
5. Conclusion.....	29
Chapitre 4 : Prétraitement et Préparation des Données	32
1. Introduction	32
2. Prétraitement des Images	32
2.1. Redimensionnement et Normalisation	32
2.2. Pipeline de Data Augmentation	32
3. Gestion du Déséquilibre des Classes.....	32
3.1. WeightedRandomSampler	32
3.2. Class Weights dans la Fonction de Perte	32
4. Prétraitement des Données Tabulaires	32
4.1. Imputation des Valeurs Manquantes	32
4.2. Encodage et Normalisation	32
5. Découpage Train / Validation / Test	33
6. Conclusion	33
Chapitre 5 : Modèles et Entraînement	34
1. Introduction	34
2. CNN from Scratch — Baseline	34
2.1. Justification de l'Approche Baseline	34
2.2. Architecture Proposée	34
2.3. Hyperparamètres et Entraînement	34
2.4. Résultats et Analyse	34
3. Transfer Learning — EfficientNetBo	34
3.1. Choix de l'Architecture	34
3.2. Stratégie d'Entraînement en Deux Phases	34
3.3. Résultats et Analyse	35
4. Comparaison des Deux Approches CNN	35
4.1. Analyse Quantitative.....	35
4.2. Analyse des Courbes d'Apprentissage.....	35
4.3. Conclusion Comparative	35
5. Random Forest — Données Tabulaires.....	35
5.1. Choix du Modèle	35
5.2. Optimisation des Hyperparamètres.....	35
5.3. Feature Importance.....	35
6. Conclusion	35
Chapitre 6 : Évaluation et Résultats	37
1. Introduction	37
2. Métriques d'Évaluation.....	37
2.1. Choix et Justification des Métriques	37

2.2. Métriques Complémentaires	37
3. Résultats Finaux	37
3.1. Résultats du CNN from Scratch	37
3.2. Résultats d'EfficientNetBo	37
3.3. Résultats du Random Forest	37
4. Matrices de Confusion	37
5. Grad-CAM — Explicabilité Visuelle	38
5.1. Principe et Implémentation	38
5.2. Analyse des Heatmaps	38
6. Discussion des Résultats	38
7. Conclusion	38
Chapitre 7 : Application Web — MelanoScan	40
1. Introduction	40
2. Architecture Globale de la Plateforme	40
2.1. Vue d'Ensemble	40
2.2. Stack Technologique	40
3. Backend — API FastAPI	40
3.1. Endpoints Développés	40
3.2. Intégration des Modèles IA	40
4. Frontend — Interface React/Vite	40
4.1. Formulaire de Saisie Clinique	40
4.2. Module d'Upload d'Image	40
4.3. Affichage des Résultats et Rapport PDF	41
5. Démonstration et Cas d'Utilisation	41
6. Conclusion	41
Chapitre 8 : Conclusion Générale et Perspectives	42
1. Synthèse des Travaux Réalisés	42
2. Réponse à la Problématique	42
3. Apports Scientifiques et Techniques	42
4. Limites du Projet	42
5. Perspectives d'Amélioration	42
5.1. Fusion Multimodale	42
5.2. Diversification du Dataset	42
5.3. Déploiement et Certification	42
6. Conclusion Finale	43

PARTIE I

Contexte Clinique et Exploration des Données

Ancrage médical, revue de la littérature et analyse du dataset HAM10000

Chapitre 1 — Introduction Générale

Chapitre 2 — État de l'Art

Chapitre 3 — Dataset et Analyse Exploratoire

Chapitre 1 : Introduction Générale

1. Introduction

Dans un monde où les maladies chroniques progressent à une vitesse préoccupante, le cancer de la peau occupe une place particulière parmi les pathologies les plus surveillées par la communauté médicale internationale. Si la majorité des cancers cutanés demeurent traçables et curables lorsqu'ils sont détectés à un stade précoce, le mélanome fait figure d'exception redoutable : silencieux dans ses premières phases, il peut évoluer en quelques mois vers des formes métastatiques engageant le pronostic vital du patient. Face à ce constat, la rapidité et la fiabilité du diagnostic constituent des enjeux médicaux de premier ordre.

C'est précisément dans cette brèche que l'intelligence artificielle s'est imposée comme un levier prometteur. Au cours des dernières années, les avancées spectaculaires du Deep Learning — et plus particulièrement des réseaux de neurones convolutifs — ont ouvert la voie à des systèmes capables d'analyser des images médicales avec une précision rivalisant, voire dépassant, celle de spécialistes expérimentés. Ces progrès ont suscité un intérêt croissant pour le développement d'outils d'aide au diagnostic accessibles, explicables et fiables.

C'est dans ce contexte scientifique et médical que s'inscrit le présent Projet de Fin d'Études, réalisé au sein de la Faculté des Sciences Ben M'Sik de l'Université Hassan II de Casablanca, dans le cadre de la Licence d'excellence en Intelligence Artificielle. Ce projet propose la conception et le développement de **MelanoScan**, une plateforme intelligente et multimodale d'aide à la détection du mélanome, reposant sur le dataset dermatologique de référence HAM10000. La plateforme combine trois moteurs d'inférence complémentaires — un réseau de neurones convolutif léger construit from scratch, un modèle pré-entraîné ConvNext affiné par Transfer Learning, et un modèle de Machine Learning classique (Random Forest) — le tout intégré dans une interface web moderne et accessible.

Le présent chapitre a pour vocation d'introduire ce travail dans son ensemble. Il expose le contexte général dans lequel s'inscrit la problématique traitée, formule la question de recherche centrale, puis décline les objectifs poursuivis à travers ce projet. Il se clôt par une présentation de l'organisation générale du rapport, guidant le lecteur à travers les différentes étapes de notre démarche.

2. Contexte Général

Le mélanome malin constitue l'un des défis les plus pressants de la médecine moderne. Bien qu'il ne représente qu'environ 1 % de l'ensemble des cancers cutanés, il est responsable de la grande majorité des décès liés à cette catégorie de pathologies. Cette dangerosité s'explique par une dynamique biologique singulière : une fois que la tumeur dépasse la barrière cutanée pour atteindre le système lymphatique ou sanguin, ses capacités de dissémination métastatique s'accroissent, rendant les traitements conventionnels nettement moins efficaces.

À l'échelle mondiale, l'incidence du mélanome a connu une croissance constante au cours des dernières décennies. Ce phénomène est accentué par des facteurs environnementaux, tels que l'exposition accrue aux rayonnements ultraviolets, mais aussi par une amélioration des capacités de dépistage. Toutefois, cette augmentation du nombre de cas exerce une pression considérable sur les systèmes de santé et, plus spécifiquement, sur les services de dermatologie spécialisés.

Traditionnellement, le diagnostic repose sur une inspection visuelle rigoureuse, souvent guidée par des critères cliniques tels que la règle ABCDE (Asymétrie, Bords, Couleur, Diamètre, Évolution) et complétée par l'examen dermoscopique. Cependant, cette approche, bien qu'éprouvée, demeure intrinsèquement subjective et dépendante de l'expertise du praticien. Le "standard d'or" reste la biopsie cutanée, une procédure invasive, coûteuse et génératrice de délais d'attente qui peuvent s'avérer critiques pour le pronostic du patient.

Dans ce contexte, l'émergence d'outils de dépistage non invasifs, capables de réaliser un premier tri automatisé avec une haute sensibilité, n'est plus seulement une opportunité technologique, mais une nécessité de santé publique. C'est ici que l'intelligence artificielle, alimentée par des bases de données massives et diversifiées comme le dataset HAM10000, propose un changement de paradigme : transformer l'image dermoscopique d'une simple observation visuelle en une donnée mathématique complexe, exploitable pour une prédiction précoce et objective.

3. Problématique

La problématique de ce projet repose sur la nécessité de fournir une aide au diagnostic à la fois complète et accessible, tout en respectant les contraintes techniques liées à la nature hétérogène des données dermatologiques. Si l'examen visuel reste prédominant, l'isolement de l'image par rapport au contexte clinique du patient constitue une limite majeure des systèmes d'aide au diagnostic simplistes.

L'intégration de l'intelligence artificielle dans ce domaine soulève alors trois défis fondamentaux auxquels ce travail apporte des réponses adaptées :

1. **Le défi de l'analyse hybride par modèles indépendants** : Un diagnostic dermatologique fiable s'appuie sur deux piliers : l'observation de la lésion et l'étude du profil clinique (âge, sexe, localisation). Comment concevoir une architecture logicielle capable d'exploiter ces deux dimensions de manière complémentaire, en faisant cohabiter des réseaux de neurones convolutifs pour l'imagerie et des modèles de Machine Learning classique pour les données tabulaires ?
2. **Le défi de l'équité face au déséquilibre des classes** : Le dataset HAM10000 présente une forte prédominance de cas bénins. Comment garantir que nos modèles, qu'ils soient visuels ou tabulaires, ne développent pas un biais en faveur de la classe majoritaire et conservent une sensibilité élevée pour la détection du mélanome, malgré sa rareté statistique dans les données d'entraînement ?
3. **Le défi de la transparence et de l'explicabilité** : Pour qu'un outil d'IA soit véritablement utile au praticien, il ne doit pas fonctionner comme une "boîte noire". Comment assurer la transparence des prédictions, notamment pour le modèle de vision, en mettant en évidence les zones de l'image ayant conduit à la décision algorithmique ?

En définitive, la question centrale de ce projet est la suivante : **Comment développer une plateforme unifiée capable d'orchestrer des modèles d'IA spécialisés et indépendants afin d'offrir une évaluation multiforme du risque de mélanome, alliant performance prédictive et clarté diagnostique ?**

4. Objectifs du Projet

4.1. Objectif Principal

L'objectif central de ce projet est de concevoir et de réaliser une plateforme web d'aide au diagnostic, intitulée **MelanoScan**, capable d'assister les praticiens et les utilisateurs dans l'évaluation précoce du risque de mélanome.

Il ne s'agit pas seulement de produire un algorithme de classification, mais de bâtir un écosystème technologique complet où l'intelligence artificielle est mise au service de la décision clinique. Cet objectif se traduit par le développement d'un outil capable de traiter séparément, mais de manière cohérente, les deux piliers de l'examen dermatologique : l'analyse morphologique de la lésion par la vision par ordinateur et l'étude des facteurs de risque à travers les métadonnées cliniques du patient. En définitive, MelanoScan vise à

transformer des données médicales hétérogènes en une estimation de risque fiable, transparente et facilement accessible via une interface moderne.

4.2. Objectifs Spécifiques

Pour atteindre l'objectif principal de ce projet, nous avons décliné notre démarche en plusieurs objectifs opérationnels et techniques :

1. **Analyse et ingénierie des données** : Réaliser une analyse exploratoire (EDA) approfondie du dataset HAM10000 afin d'en identifier les biais et les limitations. Cela inclut la mise en place d'un pipeline de prétraitement robuste pour les images et les données tabulaires, ainsi que l'implémentation de solutions mathématiques (comme le *WeightedRandomSampler*) pour traiter le déséquilibre massif entre les classes de lésions.
2. **Étude comparative des architectures de vision** : Développer et entraîner un réseau de neurones convolutif (CNN) personnalisé "from scratch" pour servir de base de référence (*Baseline*). En parallèle, implémenter une stratégie de *Transfer Learning* avec l'architecture EfficientNetBo et ConvNext afin de démontrer et de quantifier l'apport des modèles pré-entraînés sur la précision et la sensibilité du diagnostic.
3. **Modélisation des facteurs de risque cliniques** : Concevoir et optimiser un modèle de Machine Learning indépendant (Random Forest) dédié spécifiquement à l'analyse des métadonnées cliniques (âge, sexe, localisation), permettant d'extraire une probabilité de risque fondée sur le profil du patient.
4. **Intégration de l'explicabilité visuelle** : Implémenter l'algorithme Grad-CAM au sein du modèle de vision pour générer des cartes de chaleur (*heatmaps*). L'objectif est de transformer la prédiction en un outil transparent, capable d'indiquer visuellement les zones de la lésion ayant motivé la décision de l'IA.
5. **Développement et déploiement de l'écosystème MelanoScan** : Construire une application web full-stack reposant sur une architecture moderne (FastAPI pour le backend et React pour le frontend). Cette interface doit orchestrer les différents moteurs d'inférence de manière fluide et permettre la génération d'un rapport de diagnostic préliminaire clair pour l'utilisateur final.

5. Organisation du Rapport

Afin de refléter fidèlement le cheminement scientifique et technique de notre démarche, ce manuscrit s'articule autour de trois grandes parties complémentaires, regroupant les chapitres du projet :

- **La Partie I : Contexte Clinique et Exploration des Données** pose le cadre fondamental de notre étude. À la suite de cette introduction générale (Chapitre 1), le Chapitre 2 propose un état de l'art détaillé sur le mélanome et les avancées de l'IA en dermatologie. Le Chapitre 3 se consacre ensuite à la présentation et à l'analyse exploratoire (EDA) du dataset HAM10000, mettant en lumière ses caractéristiques et ses biais structurels.
- **La Partie II : Ingénierie de l'IA et Modélisation** constitue le cœur technique du projet. Le Chapitre 4 détaille les pipelines de prétraitement des données images et tabulaires, ainsi que les stratégies de gestion du déséquilibre des classes. Le Chapitre 5 expose l'architecture et l'entraînement de nos quatre modèles d'inférence (CNN from scratch, EfficientNetBo, ConvNext et Random Forest). Enfin, le Chapitre 6 présente l'évaluation rigoureuse de ces modèles sur le jeu de test, appuyée par des métriques adaptées au domaine médical et l'explicabilité visuelle via Grad-CAM.
- **La Partie III : Réalisation et Bilan** illustre l'aboutissement applicatif de nos recherches. Le Chapitre 7 est dédié à l'architecture logicielle et au développement de la plateforme web MelanoScan, intégrant le backend et le frontend. Pour clore ce manuscrit, le Chapitre 8 dresse une synthèse générale des travaux accomplis, discute des limites rencontrées et ouvre des perspectives d'amélioration continue pour l'avenir de l'outil.

6. Conclusion

Ce premier chapitre a permis de poser les jalons de notre étude en soulignant l'urgence médicale liée au mélanome et les défis technologiques complexes que pose son diagnostic automatisé. En définissant une problématique centrée sur la multimodalité des données et l'explicabilité des modèles, nous avons tracé la feuille de route de la plateforme MelanoScan à travers des objectifs techniques et applicatifs précis.

Toutefois, pour transformer ces ambitions en une solution robuste et scientifiquement fondée, il est impératif de s'appuyer sur le socle des connaissances existantes. C'est pourquoi le chapitre suivant sera consacré à un état de l'art approfondi, explorant à la fois les aspects cliniques de la pathologie et l'évolution des techniques d'intelligence artificielle qui façonnent aujourd'hui la dermatologie computationnelle.

Chapitre 2 : État de l'Art

1. Introduction

Ce chapitre passe en revue les travaux existants dans le domaine de la détection automatique du mélanome et positionne notre approche par rapport à la littérature scientifique.

2. Le Mélanome : Aspects Médicaux

2.1. Définition et Épidémiologie

Le mélanome est un cancer malin issu des mélanocytes, cellules productrices de mélanine, et représente la forme la plus mortelle des cancers cutanés malgré une incidence relativement faible.

2.2. Diagnostic Clinique Traditionnel

Le diagnostic du mélanome repose sur la règle ABCDE (Asymétrie, Bords, Couleur, Diamètre, Évolution) et sur l'examen dermoscopique réalisé par un dermatologue expérimenté.

3. Intelligence Artificielle en Dermatologie

3.1. Premiers Travaux sur la Classification de Lésions

Les premières applications d'apprentissage automatique à la classification de lésions cutanées remontent aux années 2010, avec l'utilisation de features manuelles extraites d'images dermoscopiques.

3.2. Émergence du Deep Learning

L'avènement des réseaux de neurones convolutifs profonds a transformé la dermatologie computationnelle, avec des modèles atteignant des performances comparables à celles de dermatologues certifiés.

3.3. Travaux sur le Dataset HAM10000

Plusieurs travaux de référence ont exploité le dataset HAM10000 pour la classification multi-classes de lésions cutanées, obtenant des précisions supérieures à 85% avec des architectures de Transfer Learning.

4. Comparaison des Approches CNN

4.1. CNN Entraîné from Scratch

Les CNN entraînés from scratch sur des datasets médicaux de taille limitée montrent systématiquement des signes de surapprentissage, justifiant le recours aux modèles pré-entraînés.

4.2. Transfer Learning

Le Transfer Learning exploitant des poids pré-entraînés sur ImageNet permet d'atteindre de meilleures performances avec moins de données, en bénéficiant de features génériques apprises sur des millions d'images.

5. Positionnement de Notre Travail

Notre approche se distingue par la comparaison rigoureuse des deux paradigmes CNN sur HAM10000, combinée à l'intégration d'un modèle tabulaire et d'une interface web complète dans une plateforme unifiée.

6. Conclusion

L'analyse de la littérature confirme la pertinence du Transfer Learning pour notre contexte et justifie la démarche comparative adoptée dans ce projet.

Chapitre 3 : Dataset et Analyse Exploratoire

1. Introduction

Toute démarche d'apprentissage automatique repose sur une prémisse fondamentale : la qualité et la compréhension des données conditionnent directement la pertinence des modèles qui en sont issus. Avant d'entraîner le moindre réseau de neurones ou d'ajuster le moindre hyperparamètre, il est impératif de s'immerger dans les données, de les questionner, de les visualiser et d'en déceler les caractéristiques cachées — qu'il s'agisse de déséquilibres structurels, de valeurs aberrantes ou de biais démographiques susceptibles de compromettre la généralisation des résultats.

Ce chapitre est entièrement consacré à cette étape fondatrice qu'est l'analyse exploratoire des données, appliquée au dataset **HAM10000** (*Human Against Machine with 10000 training images*), le corpus dermatologique de référence sur lequel repose l'intégralité de notre travail. Ce dataset, publié dans le cadre du challenge international ISIC (*International Skin Imaging Collaboration*), constitue aujourd'hui l'un des benchmarks les plus cités dans la littérature scientifique consacrée à la classification automatique des lésions cutanées.

Nous commençons par présenter le dataset dans sa globalité : son origine, sa composition, les sept types de lésions qu'il recense et les métadonnées cliniques qui accompagnent chaque image. Nous procédons ensuite à une analyse exploratoire rigoureuse couvrant la distribution des classes, les caractéristiques démographiques des patients, ainsi que l'inventaire des valeurs manquantes. Nous clôturons ce chapitre par une discussion critique des biais et limitations inhérents au dataset, une étape indispensable pour interpréter avec honnêteté les performances des modèles présentés dans les chapitres ultérieurs.

L'ensemble des visualisations produites lors de cette phase d'exploration — graphiques de distribution, analyses démographiques et heatmaps de corrélation — sont répertoriées tout au long de ce chapitre et constituent les livrables directs du notebook `01_exploration.ipynb`.

2. Présentation du Dataset HAM10000

2.1. Origine et Description

Le dataset **HAM10000**, acronyme de « *Human Against Machine with 10,000 training images* », constitue un benchmark de référence incontournable dans le domaine de la dermatologie computationnelle. Ce corpus a été méticuleusement constitué et publié pour servir de base de données d'entraînement officielle lors du challenge international de l'**ISIC**

(*International Skin Imaging Collaboration*), et il est aujourd'hui accessible publiquement via des plateformes de recherche telles que l'ISIC Archive et Harvard Dataverse.


Ce jeu de données est le fruit d'une collaboration internationale entre des institutions médicales de premier plan, notamment le département de dermatologie de l'Université médicale de Vienne en Autriche et la clinique dermatologique Cliff Rosendahl dans le Queensland, en Australie. Il se compose précisément de **10 015 images dermatoscopiques** de haute résolution, capturées sur une période de plus de vingt ans.

La valeur scientifique de HAM10000 repose sur deux piliers fondamentaux :

1. **La qualité de l'imagerie** : Contrairement aux photographies cliniques standards, la dermatoscopie utilise une lumière polarisée et un grossissement spécifique pour éliminer les reflets de surface de la peau. Cette technique permet de visualiser les structures morphologiques et les motifs pigmentaires situés sous la couche cornée, offrant ainsi une profondeur d'analyse indispensable pour distinguer les lésions malignes des lésions bénignes.
2. **La rigueur de la vérité terrain (*Ground Truth*)** : Afin de garantir la fiabilité absolue des étiquettes (labels), chaque diagnostic présent dans le dataset a été validé par des méthodes de référence. Plus de la moitié des cas (53,3 %) ont été confirmés par **analyse histopathologique** (biopsie), ce qui représente le « standard d'or » en médecine. Pour le reste des images, la validation a été obtenue par un consensus d'experts dermatologues, par microscopie confocale *in vivo* ou par un suivi clinique longitudinal rigoureux prouvant la stabilité de la lésion dans le temps.

Cette base de données offre ainsi un environnement d'apprentissage robuste et médicalement certifié, indispensable pour entraîner des modèles de réseaux de neurones capables de généraliser sur des cas réels de dépistage du mélanome.

La figure ci-dessous illustre un échantillon représentatif des images dermatoscopiques du dataset, permettant d'appréhender visuellement la diversité morphologique et chromatique des sept classes de lésions :



2.2. Les 7 Classes de Lésions

Le dataset HAM10000 couvre sept types distincts de lésions cutanées pigmentées, soigneusement sélectionnés pour représenter le spectre clinique le plus fréquemment rencontré en consultation dermatologique. Ces lésions se répartissent en trois catégories pronostiques : les lésions malignes, les lésions potentiellement malignes, et les lésions bénignes.

1. **Le Mélanome (mel)** constitue la classe cible principale de notre projet. Il s'agit d'un carcinome malin issu de la transformation néoplasique des mélanocytes, les cellules responsables de la pigmentation cutanée. Le mélanome est la forme la plus létale des cancers cutanés : bien qu'il ne représente qu'environ 11 % des images du dataset, sa détection correcte est l'enjeu médical central de toute plateforme d'aide au diagnostic dermatologique. Son aspect dermatoscopique est caractérisé par une asymétrie marquée, des bords irréguliers, une polychromie et parfois des structures vasculaires atypiques.
2. **Le Nævus Mélanocytaire (nv)** est la classe majoritaire du dataset, représentant à elle seule près de 67 % des images. Il s'agit de lésions bénignes communément appelées "grains de beauté", résultant d'une prolifération localisée et contrôlée des mélanocytes. Leur ressemblance visuelle avec certains mélanomes précoces en fait la principale source de confusion pour les modèles de classification, et justifie la nécessité d'architectures profondes capables de saisir des caractéristiques subtiles de différenciation.
3. **Le Carcinome Basocellulaire (bcc)** est le cancer de la peau le plus répandu dans la population générale, bien qu'il soit sous-représenté dans HAM10000. Il se développe à partir des cellules basales de l'épiderme et présente un caractère malin local — il envahit les tissus adjacents mais métastase rarement. En dermatoscopie, il se caractérise typiquement par la présence de structures arborisantes vasculaires bleutées et de zones blanc-brillant.
4. **La Kératose Actinique (akiec)** représente une lésion précancéreuse induite par une exposition prolongée et cumulative aux rayonnements ultraviolets. Elle est considérée comme un stade intermédiaire entre une lésion bénigne et un carcinome épidermoïde invasif. Sa détection précoce revêt une importance préventive capitale, car un traitement adapté à ce stade permet d'éviter la progression vers la malignité.
5. **La Kératose Bénigne (bkl)** regroupe sous une même étiquette plusieurs entités cliniques d'apparence similaire : la kératose séborrhéique, le lentigo solaire et le lichen plan pigmentogène. Toutes sont des lésions strictement bénignes, sans potentiel malin, mais dont l'aspect dermoscopique hétérogène peut parfois prêter à confusion avec des lésions plus préoccupantes.
6. **Le Dermatofibrome (df)** est une tumeur cutanée bénigne d'origine fibroblastique, généralement de petite taille et ferme à la palpation. Il est fortement sous-représenté dans le dataset — ce qui en fait l'une des classes les plus difficiles à apprendre pour un modèle confronté au déséquilibre. Son signe dermatoscopique

le plus caractéristique est la présence d'un réseau pigmenté périphérique associé à une zone centrale blanchâtre.

7. **La Lésion Vasculaire (vasc)** désigne un ensemble hétérogène de lésions d'origine vasculaire, incluant les angiomes, les angiofibromes et les lacs veineux. Comme le dermatofibrome, cette classe est très minoritaire dans le dataset. En dermatoscopie, ces lésions se distinguent par des lacunes rouges ou violacées bien délimitées, reflétant leur nature vasculaire.

Le tableau suivant synthétise, pour chaque classe, son abréviation, son nom complet, sa nature clinique et sa représentation relative dans le dataset :

Abrév.	Nom complet	Nature clinique	Effectif	% du dataset
<i>nv</i>	Nævus mélanocytaire	Bénin	6 705	66.9 %
<i>mel</i>	Mélanome	Malin	1 113	11.1 %
<i>bkl</i>	Kératose bénigne	Bénin	1 099	11.0 %
<i>bcc</i>	Carcinome basocellulaire	Malin	514	5.1 %
<i>akiec</i>	Kératose actinique	Potentiellement malin	327	3.3 %
<i>vasc</i>	Lésion vasculaire	Bénin	142	1.4 %
<i>df</i>	Dermatofibrome	Bénin	115	1.1 %

2.3. Données Tabulaires Disponibles

Au-delà des images dermatoscopiques, le dataset HAM10000 se distingue d'un simple corpus visuel par la richesse des métadonnées cliniques qui accompagnent chaque image. Ces informations, regroupées dans le fichier `HAM10000_metadata.csv`, constituent une source d'information complémentaire précieuse qui reflète la réalité du processus diagnostique médical : en pratique clinique, un dermatologue ne se base jamais uniquement sur l'aspect visuel d'une lésion — il l'interprète toujours dans le contexte du profil du patient.

Ce fichier CSV associe à chaque image un ensemble de variables structurées, que l'on peut regrouper en trois catégories distinctes.

Les variables d'identification permettent de relier chaque entrée à son image correspondante et à son patient d'origine. L'identifiant unique de l'image (`lesion_id`) et celui du patient (`image_id`) assurent la traçabilité des données et permettent de détecter les cas où plusieurs images représentent la même lésion chez le même patient — une

particularité du dataset qui doit être prise en compte lors de la construction des splits train/validation/test afin d'éviter toute fuite de données entre les partitions.

La variable cible (dx**)** contient le diagnostic confirmé de la lésion, exprimé sous forme d'une des sept abréviations présentées en section 2.2. C'est cette variable qui constitue l'étiquette d'entraînement pour nos trois modèles. Elle est complétée par la variable **dx_type** qui précise la méthode de confirmation diagnostique utilisée — histopathologie, consensus d'experts, microscopie confocale ou suivi longitudinal — offrant ainsi un indicateur de confiance sur la fiabilité de chaque étiquette.

Les variables cliniques du patient sont au nombre de trois, et constituent les features d'entrée directes du modèle Random Forest développé dans ce projet :

- **age** : l'âge du patient au moment de l'examen, exprimé en années. Cette variable numérique continue est cliniquement pertinente car le risque de mélanome augmente significativement avec l'âge, avec une incidence maximale observée entre 50 et 70 ans dans les populations occidentales.
- **sex** : le sexe biologique du patient, encodé sous forme de variable catégorielle prenant les valeurs **male**, **female** ou **unknown**. Cette variable présente une valeur discriminante modérée, certaines lésions présentant une prévalence différenciée selon le sexe.
- **localization** : la localisation anatomique de la lésion cutanée, exprimée sous forme de variable catégorielle à 15 modalités distinctes — dos, abdomen, visage, membres inférieurs, membres supérieurs, tronc, cuir chevelu, entre autres. Cette variable est cliniquement très informative : la localisation d'une lésion est l'un des critères que les dermatologues intègrent systématiquement dans leur raisonnement diagnostique, le mélanome étant par exemple plus fréquemment observé dans le dos chez l'homme et dans les membres inférieurs chez la femme.

Le tableau suivant présente une synthèse structurée de ces variables, incluant leur type, leurs modalités et leur rôle dans le projet :

Variable	Type	Modalités / Plage	Valeurs manquantes	Rôle dans le projet
VARIABLES D'IDENTIFICATION				
<i>lesion_id</i>	Chaîne de caractères	Identifiant unique de la lésion	Aucune	Traçabilité — détecter les lésions dupliquées entre patients

Variable	Type	Modalités / Plage	Valeurs manquantes	Rôle dans le projet
<i>image_id</i>	Chaîne de caractères	Nom du fichier image (ex: ISIC_0024306)	Aucune	Liaison entre le CSV et les fichiers images JPEG
VARIABLE CIBLE				
<i>dx</i>	Catégorielle (7 classes)	mel, nv, bcc, akiec, bkl, df, vasc	Aucune	Étiquette d'entraînement des 3 modèles IA (Random Forest, CNN Scratch, EfficientNetB0)
<i>dx_type</i>	Catégorielle (4 valeurs)	histo, follow_up, consensus, confocal	Aucune	Indicateur de fiabilité du label — histo = gold standard médical
VARIABLES CLINIQUES DU PATIENT — FEATURES DU RANDOM FOREST				
<i>age</i>	Numérique continue	5 — 85 ans (médiane ≈ 45 ans)	57 valeurs manquantes	Feature 1/3 du RF — standardisée via StandardScaler avant entraînement
<i>sex</i>	Catégorielle (3 valeurs)	male, female, unknown	0 valeur manquante	Feature 2/3 du RF — encodée en One-Hot (3 colonnes binaires)
<i>localization</i>	Catégorielle (15 valeurs)	back, abdomen, face, lower extremity, upper extremity, trunk, scalp...	0 valeur manquante	Feature 3/3 du RF — encodée en One-Hot (15 colonnes) → vecteur final de 21 features


Il est important de souligner dès à présent que ces trois variables cliniques présentent quelques imperfections mineures. La variable **age** comporte **57 valeurs manquantes**, soit environ **0.57 %** des entrées du dataset — une proportion faible mais qui nécessite néanmoins une stratégie d'imputation adaptée pour éviter toute perte d'information lors de l'entraînement. La variable **sex**, quant à elle, comporte une modalité **unknown** pour les cas où l'information patient n'était pas disponible. Ces points, détaillés en section 3.3, seront traités lors de la phase de prétraitement décrite au chapitre 4.

3. Analyse Exploratoire des Données (EDA)

3.1. Distribution des Classes

La première étape de toute analyse exploratoire sérieuse consiste à examiner la distribution des classes au sein du dataset. Cette étape est particulièrement critique dans le contexte de la classification médicale, où un déséquilibre prononcé entre les classes peut conduire un modèle à développer un biais systématique en faveur des classes majoritaires, au détriment précisément des classes minoritaires — souvent les plus importantes cliniquement.

L'examen de la distribution des 10 015 images du dataset HAM10000 révèle un déséquilibre structurel majeur, dont l'ampleur est illustrée par la figure suivante :



La lecture de cette figure appelle plusieurs observations importantes.

Une classe écrasante domine le dataset. Le naevus mélanocytaire (nv) représente à lui seul **6 705 images**, soit **66.9 %** de l'intégralité du corpus. Cette surreprésentation massive n'est pas le fruit d'un biais de collecte délibéré, mais reflète la réalité épidémiologique : les grains de beauté sont de loin les lésions cutanées pigmentées les plus fréquemment rencontrées en consultation dermatologique.

La classe cible est minoritaire. Le mélanome (mel), qui constitue pourtant l'enjeu diagnostique central de ce projet, ne compte que **1 113 images**, soit **11.1 %** du dataset. Ce chiffre, bien qu'il puisse sembler acceptable en valeur absolue, devient préoccupant lorsqu'on le rapporte au ratio de déséquilibre avec la classe majoritaire : le naevus mélanocytaire est représenté **6 fois plus** que le mélanome dans le dataset.

Trois classes sont sévèrement sous-représentées. La kératose actinique (akiec) avec 327 images (3.3 %), la lésion vasculaire (vasc) avec 142 images (1.4 %) et le dermatofibrome (df) avec seulement 115 images (1.1 %) constituent les classes les plus vulnérables au phénomène d'oubli catastrophique — un modèle non corrigé aura naturellement tendance à ignorer ces classes pour optimiser son accuracy globale.

Le tableau suivant synthétise ces observations en quantifiant précisément le déséquilibre :

Classe	Nom complet	Effectif	% dataset	Représentation	Ratio vs mel	Niveau déséquilibre
<i>nv</i>	Nævus mélanocytaire	6 705	66.9 %		×6.0	Extrême
<i>mel</i>	Mélanome ★	1 113	11.1 %		—	Référence (cible)
<i>bkl</i>	Kératose bénigne	1 099	11.0 %		×0.98	Équilibré
<i>bcc</i>	Carcinome basocellulaire	514	5.1 %		×0.46	Modéré
<i>akiec</i>	Kératose actinique	327	3.3 %		×0.29	Élevé
<i>vasc</i>	Lésion vasculaire	142	1.4 %		×0.13	Très élevé
<i>df</i>	Dermatofibrome	115	1.1 %		×0.10	Extrême (×58 nv)
TOTAL	—	10 015	100 %		—	Ratio max : ×58.3 (nv/df)

Ratio vs mel est le rapport entre l'effectif de chaque classe et celui du mélanome. Permet de voir que nv est 6× plus représenté que mel.

Pour illustrer la magnitude de ce déséquilibre, il est utile de calculer le **ratio de déséquilibre** entre la classe la plus représentée et chacune des classes minoritaires. Ce ratio atteint **58.3** entre le nævus mélanocytaire et le dermatofibrome — signifiant qu'il existe près de 58 fois plus d'images de nævus que de dermatofibromes dans le dataset. Un tel écart est qualifié de déséquilibre extrême dans la littérature de l'apprentissage automatique, et justifie le recours à des stratégies de compensation dédiées.

Face à ce constat, le projet s'appuie sur une stratégie d'équilibrage dynamique pour atténuer l'impact de cette disparité sur les performances du modèle d'imagerie. L'approche centrale repose sur l'implémentation d'un algorithme d'échantillonnage probabiliste (`WeightedRandomSampler`) lors de la construction des lots d'entraînement. Ce mécanisme attribue à chaque image un poids de tirage inversement proportionnel à la fréquence globale de sa classe diagnostique. Ainsi, le réseau de neurones est forcé d'examiner une proportion équitable de lésions rares (comme le mélanome) et de lésions fréquentes (comme les nævus) à chaque itération d'apprentissage. Afin d'éviter l'apprentissage par cœur de ces classes minoritaires sur-échantillonnées, cette méthode est intrinsèquement couplée à un pipeline d'augmentation de données appliqué "à la volée", garantissant une variabilité visuelle continue. Ces choix d'ingénierie sont décrits de manière détaillée au chapitre 4.


3.2. Analyse des Métadonnées Tabulaires

Si la distribution des classes renseigne sur la composition visuelle du dataset, l'analyse des métadonnées tabulaires offre une lecture complémentaire et indispensable : elle permet de comprendre le profil démographique et clinique des patients dont les lésions ont été collectées, et d'évaluer la pertinence prédictive des variables cliniques disponibles pour le modèle Random Forest.

Cette analyse porte sur les trois variables cliniques identifiées en section 2.3 : l'âge (**age**), le sexe (**sex**) et la localisation anatomique (**localization**).


Distribution de l'âge des patients

L'âge constitue l'une des variables cliniques les plus informatives pour la classification des lésions cutanées. En dermatologie, le risque de développer un mélanome augmente significativement avec l'avancée en âge, avec une incidence maximale observée dans les tranches d'âge comprises entre 50 et 70 ans dans les populations caucasiennes.



L'analyse de la distribution de l'âge révèle que la majorité des patients inclus dans HAM10000 appartiennent à des tranches d'âge relativement avancées, avec une médiane située autour de 45 ans. Cette répartition est cohérente avec les données épidémiologiques internationales sur les cancers cutanés, qui demeurent rares chez les patients jeunes et progressent en fréquence après 40 ans. Il est cependant important de noter que cette concentration démographique introduit une limite implicite : les modèles entraînés sur ce dataset pourraient présenter des performances dégradées pour des patients jeunes, sous-représentés dans le corpus.


Répartition par sexe



La répartition par sexe indique une légère surreprésentation des patients masculins dans le dataset. Cette observation est cliniquement cohérente avec les données épidémiologiques : le mélanome présente une incidence légèrement supérieure chez l'homme, notamment en raison d'une exposition solaire professionnelle et récréative historiquement plus élevée dans les populations masculines. La modalité `unknown`, bien que minoritaire, témoigne des limites inhérentes à la collecte rétrospective de données médicales sur une période de plus de vingt ans.

Localisation anatomique des lésions

La localisation anatomique est, parmi les trois variables cliniques disponibles, celle qui présente la plus grande richesse informative pour un modèle de classification. En pratique clinique, la localisation d'une lésion est systématiquement intégrée dans le raisonnement diagnostique du dermatologue : certaines lésions présentent en effet des sites anatomiques de prédilection bien documentés dans la littérature médicale.




L'analyse de cette distribution révèle que le dos (**back**) constitue la localisation la plus fréquemment représentée dans le dataset, suivi par les membres inférieurs (**lower extremity**) et le tronc (**trunk**). Cette répartition est médicalement significative : le mélanome est statistiquement plus fréquent dans le dos chez l'homme et dans les membres inférieurs chez la femme, ce qui confère à la variable **localization** une valeur discriminante réelle pour la tâche de classification.

Par ailleurs, la diversité des 15 modalités de cette variable — allant du cuir chevelu (**scalp**) aux paumes des mains (**palms**) — implique un encodage One-Hot produisant un vecteur de 15 colonnes binaires, ce qui représente la part la plus volumineuse du vecteur de features du modèle Random Forest.

Corrélation entre les métadonnées et les classes diagnostiques

Au-delà de l'analyse univariée de chaque variable, il est instructif d'examiner dans quelle mesure ces métadonnées sont corrélées avec les classes diagnostiques. Cette analyse permet d'évaluer *a priori* la capacité prédictive du modèle Random Forest, qui repose exclusivement sur ces trois variables d'entrée.



L'analyse de cette heatmap révèle que **l'âge constitue de loin la variable la plus discriminante** de la matrice. Sa corrélation négative avec le nævus mélanocytaire atteint **-0.45** — la valeur la plus intense de toute la figure — confirmant que cette lésion bénigne est massivement associée aux patients jeunes. À l'inverse, l'âge présente des corrélations positives modérées avec la kératose bénigne (**+0.26**), le carcinome basocellulaire (**+0.21**) et la kératose actinique (**+0.16**), trois lésions dont l'incidence augmente avec l'exposition solaire cumulée au fil des années. La corrélation de l'âge avec le mélanome est positive mais modeste (**+0.18**), ce qui est cohérent avec son épidémiologie.

La **localisation anatomique** apporte une information complémentaire, bien que plus fragmentée. La localisation `face` se distingue comme la plus informative parmi les variables de localisation : elle est positivement corrélée avec la kératose bénigne (**+0.29**) et la kératose actinique (**+0.19**), deux lésions d'origine photo-induite, et négativement corrélée avec le nævus mélanocytaire (**-0.32**), rarement localisé sur le visage. La localisation `trunk`

est quant à elle positivement associée au *nævus* (**+0.18**), reflétant la prédilection connue des grains de beauté pour le tronc.

En revanche, les **variables de sexe** présentent des corrélations quasi nulles avec l'ensemble des classes diagnostiques, leurs valeurs n'excédant pas ± 0.08 . Leur contribution au pouvoir prédictif du modèle Random Forest sera donc marginale, ce que la Feature Importance confirmerait lors de l'entraînement.

Il convient de souligner que l'ensemble de ces corrélations demeure **modéré à faible** (valeurs inférieures à 0.30 pour la quasi-totalité des paires). Ce constat est riche d'enseignement : il démontre que les métadonnées cliniques seules ne suffisent pas à discriminer les classes de lésions avec une précision suffisante pour un usage médical, et justifie ainsi pleinement l'approche multimodale de MelanoScan, qui associe l'analyse tabulaire à celle des images dermatoscopiques.

3.3. Valeurs Manquantes

La gestion des valeurs manquantes constitue une étape incontournable de tout pipeline de traitement de données. Dans le contexte médical, une valeur absente ne représente pas simplement un vide à combler techniquement — elle témoigne d'une réalité clinique : une information qui n'a pas pu être recueillie au moment de la consultation, en raison d'un oubli de saisie, d'une donnée indisponible dans le dossier patient, ou d'une collecte rétrospective incomplète sur plus de vingt ans d'archives.

L'examen du fichier `HAM10000_metadata.csv` révèle que les valeurs manquantes sont concentrées sur une seule variable, comme l'illustre la figure suivante :

[Figure 3.7 — Carte des valeurs manquantes par variable (HAM10000_metadata.csv)]

État des lieux des valeurs manquantes


Le bilan est le suivant. Sur les sept colonnes du fichier de métadonnées, **une seule présente des valeurs manquantes** : la variable `age`, avec **57 entrées incomplètes** sur 10 015, soit **0.57 %** des enregistrements. Toutes les autres variables — `lesion_id`, `image_id`, `dx`, `dx_type`, `sex` et `localization` — sont intégralement renseignées.

Ce résultat est globalement rassurant : le taux de complétude global du dataset est supérieur à 99 %, ce qui en fait un corpus médicalement bien documenté pour sa nature rétrospective. La proportion de valeurs manquantes sur l'âge est statistiquement faible et ne compromet pas la représentativité de la variable.

Analyse des 57 valeurs manquantes de la variable `age`

Bien que leur proportion soit marginale (0.57 %), il convient d'examiner si ces 57 valeurs manquantes sont distribuées aléatoirement dans le dataset ou si elles sont concentrées dans certaines classes diagnostiques — un biais de concentration pouvant justifier une stratégie d'imputation plus sophistiquée.

Figure 3.Y — Distribution des valeurs manquantes de l'âge par classe diagnostique



La figure révèle une distribution non uniforme des valeurs manquantes : **45 des 57 entrées incomplètes (78.9 %)** appartiennent à la classe du nævus mélanocytaire (nv), et **10 (17.5 %)** à la kératose bénigne (bkl). Le mélanome, classe cible principale du projet, ne compte que **2 valeurs manquantes**, et les quatre classes restantes — carcinome basocellulaire, kératose actinique, dermatofibrome et lésion vasculaire — n'en présentent aucune.

Ce résultat permet de tirer deux conclusions importantes. D'une part, le mécanisme de disparition des données ne peut pas être qualifié de strictement **MCAR** (*Missing Completely At Random*) au sens statistique, puisque les absences sont concentrées sur deux classes spécifiques. D'autre part, cette concentration ne constitue pas un biais critique pour notre projet : les deux classes affectées (nv et bkl) sont précisément les plus représentées du dataset, avec respectivement 6 705 et 1 099 images. La perte de 57 entrées sur ce volume est donc statistiquement négligeable et ne compromet ni la représentativité de ces classes ni les performances attendues du modèle.

Ces éléments confirment que **l'imputation par la médiane** constitue une stratégie pleinement adaptée à ce contexte, sans qu'il soit nécessaire de recourir à des méthodes plus complexes telles que l'imputation multiple ou les algorithmes à base de KNN.

Stratégie d'imputation retenue

Compte tenu de la faible proportion de valeurs manquantes (0.57 %) et de leur distribution a priori aléatoire, la stratégie d'imputation retenue pour ce projet est **l'imputation par la médiane**. Ce choix est motivé par deux raisons complémentaires.

Premièrement, la médiane est une mesure de tendance centrale robuste aux valeurs extrêmes, contrairement à la moyenne qui pourrait être influencée par les patients les plus âgés ou les plus jeunes du dataset. Deuxièmement, une imputation par la médiane introduit un biais minimal sur la distribution globale de la variable, préservant ainsi les propriétés statistiques de la feature utilisée par le modèle Random Forest.

Il est important de souligner que cette imputation est appliquée **uniquement sur le jeu d'entraînement**, la médiane étant calculée exclusivement à partir des données d'entraînement puis appliquée aux données de validation et de test. Cette discipline méthodologique est indispensable pour éviter toute fuite de données (*data leakage*) entre les partitions, un biais qui conduirait à surestimer artificiellement les performances du modèle lors de l'évaluation. L'implémentation concrète de cette stratégie est détaillée au chapitre 4.

Cas particulier de la variable `sex`

Bien que la variable `sex` ne comporte aucune valeur manquante au sens strict, elle présente une modalité `unknown` qui mérite une attention particulière. Cette modalité ne représente pas une absence d'information au sens technique, mais un choix délibéré de codification lors de la constitution du dataset pour les cas où le sexe du patient était indéterminable ou non renseigné dans le dossier médical. Dans notre pipeline, cette modalité est traitée comme une **troisième catégorie à part entière** lors de l'encodage One-Hot, produisant ainsi une colonne binaire `sex_unknown` au même titre que `sex_male` et `sex_female`.

4. Biais et Limitations du Dataset

Toute démarche scientifique rigoureuse exige une discussion honnête des limites inhérentes aux données utilisées. Documenter les biais d'un dataset n'affaiblit pas un travail de recherche — au contraire, cela témoigne de la maturité analytique du chercheur et conditionne l'interprétation correcte des résultats obtenus. Cette section recense et discute

les principales limitations du dataset HAM10000 susceptibles d'influencer les performances et la généralisabilité des modèles développés dans ce projet.

4.1. Biais Démographique — Phototypes de Fitzpatrick

La limitation la plus structurelle de HAM10000 est son **biais de représentation démographique**. L'intégralité des images a été collectée dans deux centres cliniques situés en Europe (Vienne, Autriche) et en Australie (Queensland), des régions à forte prévalence de populations caucasiennes. En conséquence, le dataset est dominé par les phototypes de Fitzpatrick I à III — correspondant aux peaux claires, peu pigmentées, sensibles aux coups de soleil — au détriment des phototypes IV à VI représentant les peaux mates, foncées et très foncées.

Ce biais a des implications directes et mesurables sur nos modèles. Un réseau de neurones convolutif entraîné exclusivement sur des lésions de peaux claires apprend des caractéristiques visuelles — contrastes de pigmentation, structures dermoscopiques spécifiques — qui peuvent ne pas se généraliser correctement aux lésions de peaux plus foncées, dont les patterns dermoscopiques diffèrent significativement. En pratique, cela signifie que les performances documentées dans ce rapport ne sont valides que pour les populations dont les phototypes sont représentés dans HAM10000, et que tout déploiement clinique réel de MelanoScan nécessiterait une validation sur des datasets plus diversifiés sur le plan ethnique.

4.2. Biais Géographique et Conditions d'Acquisition

Les images du dataset ont été acquises dans deux centres cliniques distincts, sur une période de plus de vingt ans, avec des équipements de dermoscopie de générations différentes. Cette hétérogénéité des conditions d'acquisition introduit une variabilité technique dans les images — différences de résolution, de balance des couleurs, de grossissement et de protocoles de capture — qui ne reflète pas une variabilité clinique réelle entre les lésions. Bien que cette variabilité puisse avoir un léger effet régularisant sur le modèle en l'empêchant de sur-adapter à un équipement spécifique, elle constitue également une source de bruit non contrôlée dans les données d'entraînement.

4.3. Déséquilibre des Classes Revisité sous l'Angle du Biais

Le déséquilibre quantifié en section 3.1 peut également être analysé comme un biais de collecte. Le nævus mélanocytaire représentant 66.9 % du dataset, un modèle entraîné sans stratégie de compensation tendra naturellement à développer un biais de prédiction

systématique en faveur de cette classe majoritaire. Dans un contexte médical, ce biais prend une dimension critique : un modèle qui prédit "nævus" par défaut atteindrait une accuracy de 66.9 % sans avoir rien appris, tout en manquant la quasi-totalité des mélanomes. C'est précisément pour contrecarrer ce biais que les stratégies de pondération des classes et d'échantillonnage équilibré décrites au chapitre 4 sont indispensables.

4.4. Limitation des Métadonnées Cliniques

Les variables tabulaires disponibles dans HAM10000 — âge, sexe et localisation — représentent un sous-ensemble très restreint des informations cliniques qu'un dermatologue intègre réellement dans son raisonnement diagnostique. Des variables potentiellement discriminantes telles que l'indice de masse corporelle, les antécédents familiaux de mélanome, le nombre total de nævi, l'évolution de la lésion dans le temps ou le phototype du patient sont totalement absentes du dataset. Cette limitation structurelle plafonne mécaniquement les performances atteignables par le modèle Random Forest, qui ne peut exploiter que les trois variables disponibles pour produire sa prédiction.

Il est fondamental de rappeler, à l'issue de cette analyse critique, que ces limitations ne disqualifient pas HAM10000 comme support valide pour un projet académique de cette nature. Ce dataset demeure le benchmark de référence le plus utilisé dans la littérature scientifique consacrée à la classification automatique des lésions cutanées, et les résultats obtenus sur ce corpus sont directement comparables aux travaux publiés. La conscience et la documentation rigoureuse de ces biais constituent précisément ce qui transforme un projet technique en une démarche scientifique honnête et reproductible.

5. Conclusion

Ce chapitre a constitué le socle analytique sur lequel repose l'ensemble des décisions techniques prises dans les chapitres suivants. À travers une exploration méthodique et rigoureuse du dataset HAM10000, nous avons dressé un portrait complet et honnête des données qui alimentent les modèles d'intelligence artificielle de la plateforme MelanoScan.

La première étape de cette exploration a permis de caractériser précisément la composition du dataset : 10015 images dermatoscopiques réparties en sept classes de lésions cutanées, accompagnées de trois variables cliniques tabulaires — âge, sexe et localisation anatomique — dont la valeur prédictive a été évaluée à travers une analyse de corrélation. Cette analyse a révélé que l'âge constitue la variable la plus discriminante de la matrice, avec une corrélation négative forte avec le nævus mélanocytaire (-0.45), tandis que les variables de sexe s'avèrent peu informatives pour la tâche de classification.

L'analyse exploratoire a ensuite mis en lumière trois défis techniques majeurs que le projet doit impérativement adresser. Le premier est le **déséquilibre structurel des classes**, avec un ratio de 58.3 entre la classe majoritaire (nævus) et la classe la moins représentée (dermatofibrome), qui risque d'induire un biais de prédiction systématique si aucune mesure compensatoire n'est appliquée. Le deuxième est la **présence de 57 valeurs manquantes** sur la variable âge, concentrées sur les classes bénignes les plus représentées, et qui nécessite une imputation par la médiane sans recalcul sur les données de test pour éviter tout data leakage. Le troisième est la **présence d'images dupliquées** — plusieurs images représentant la même lésion chez un même patient — qui impose une stratification du split par identifiant de lésion plutôt que par identifiant d'image.

Enfin, la discussion critique des biais et limitations a permis d'identifier sept points de vigilance, dont deux de nature critique : le déséquilibre des classes et le risque de data leakage par duplication. Ces limitations ne disqualifient pas HAM10000 comme support de travail — il demeure le benchmark international de référence en dermatologie computationnelle — mais elles conditionnent l'interprétation des résultats et délimitent le périmètre de validité des modèles produits.

Le chapitre suivant détaille précisément l'implémentation de chacune de ces décisions à travers le pipeline de prétraitement et de préparation des données qui constitue la fondation technique des modèles entraînés dans ce projet.

PARTIE II

Ingénierie de l'IA et Modélisation

Prétraitement des données, entraînement des modèles et évaluation des performances

Chapitre 4 — Prétraitement et Préparation des Données

Chapitre 5 — Modèles et Entraînement

Chapitre 6 — Évaluation et Résultats

Chapitre 4 : Prétraitement et Préparation des Données

1. Introduction

Ce chapitre décrit l'ensemble des opérations de prétraitement appliquées aux données images et tabulaires afin de les préparer à l'entraînement des modèles d'intelligence artificielle.

2. Prétraitement des Images

2.1. Redimensionnement et Normalisation

Toutes les images sont redimensionnées au format 224×224 pixels requis par EfficientNetB0, puis normalisées selon les statistiques ImageNet (mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225]).

2.2. Pipeline de Data Augmentation

Un pipeline d'augmentation de données est appliqué sur le jeu d'entraînement incluant des retournements horizontaux/verticaux aléatoires, des rotations de $\pm 20^\circ$, des variations de luminosité et de contraste.

3. Gestion du Déséquilibre des Classes

3.1. WeightedRandomSampler

Le WeightedRandomSampler de PyTorch est configuré pour surreprésenter les classes minoritaires dans chaque batch d'entraînement, en calculant les poids inversement proportionnels à la fréquence de chaque classe.

3.2. Class Weights dans la Fonction de Perte

Le paramètre class_weight='balanced' est appliqué à la fois sur le modèle Random Forest et dans la fonction de perte du CNN afin de pénaliser davantage les erreurs sur les classes sous-représentées.

4. Prétraitement des Données Tabulaires

4.1. Imputation des Valeurs Manquantes

Les valeurs manquantes de la variable âge sont imputées par la médiane, tandis que les variables catégorielles sexe et localisation sont complétées par le mode de leur distribution respective.

4.2. Encodage et Normalisation

Les variables catégorielles sont transformées par encodage One-Hot, produisant un vecteur de 21 features, tandis que la variable âge est standardisée via un StandardScaler sauvegardé pour l'inférence.

5. Découpage Train / Validation / Test

Le dataset est divisé en trois sous-ensembles selon une proportion 80/10/10, en utilisant une stratification par classe afin de conserver les proportions originales dans chaque partition.

6. Conclusion

Le pipeline de prétraitement mis en place garantit la cohérence des données fournies aux modèles et adresse de manière rigoureuse les problèmes de déséquilibre et de valeurs manquantes identifiés lors de l'EDA.

Chapitre 5 : Modèles et Entraînement

1. Introduction

Ce chapitre présente les trois modèles développés dans ce projet, leur architecture respective, la stratégie d'entraînement adoptée et les résultats obtenus sur le jeu de validation.

2. CNN from Scratch — Baseline

2.1. Justification de l'Approche Baseline

Construire un CNN léger from scratch constitue une étape méthodologique nécessaire pour établir une référence de performance et démontrer quantitativement les gains apportés par le Transfer Learning.

2.2. Architecture Proposée

L'architecture proposée est composée de quatre blocs convolutifs progressifs (32, 64, 128, 256 filtres), chacun suivi d'une BatchNormalization et d'un MaxPooling, culminant en un GlobalAveragePooling et deux couches denses.

2.3. Hyperparamètres et Entraînement

Le modèle est entraîné pendant 50 époques avec l'optimiseur Adam ($lr=0.001$), une régularisation $L2$ et un mécanisme d'Early Stopping de patience 10 pour limiter le surapprentissage.

2.4. Résultats et Analyse

Les courbes d'entraînement révèlent un écart croissant entre la loss d'entraînement et de validation à partir de l'époque 14, confirmant la tendance au surapprentissage anticipée sur un dataset de cette taille.

3. Transfer Learning — EfficientNetB0

3.1. Choix de l'Architecture

EfficientNetB0 est retenu pour son excellent compromis précision/légèreté et ses performances documentées dans la littérature sur des tâches de classification médicale similaires.

3.2. Stratégie d'Entraînement en Deux Phases

La Phase A consiste à entraîner uniquement la tête de classification pendant 10 époques avec le backbone gelé, tandis que la Phase B dégèle les 30 dernières couches pour un fine-tuning à taux d'apprentissage réduit.

3.3. Résultats et Analyse

EfficientNetBo atteint une accuracy de validation de 85% et un Recall mélanome supérieur à 80%, confirmant la supériorité de l'approche Transfer Learning sur le CNN from scratch pour ce dataset.

4. Comparaison des Deux Approches CNN

4.1. Analyse Quantitative

La comparaison quantitative montre un gain de +15 à +20 points de pourcentage sur le Recall mélanome en faveur d'EfficientNetBo, ce qui est déterminant dans un contexte médical où les faux négatifs sont critiques.

4.2. Analyse des Courbes d'Apprentissage

Les courbes d'apprentissage superposées illustrent clairement l'overfitting du CNN scratch (écart train/val dès l'époque 14) contre la convergence stable et régulière d'EfficientNetBo.

4.3. Conclusion Comparative

EfficientNetBo est sélectionné comme modèle de production en raison de ses performances supérieures et de sa meilleure généralisation, le CNN scratch étant documenté comme baseline dans le rapport.

5. Random Forest — Données Tabulaires

5.1. Choix du Modèle

Le Random Forest est choisi pour sa robustesse sur les données tabulaires de faible dimensionnalité, sa résistance au surapprentissage et sa capacité à fournir une Feature Importance cliniquement interprétable.

5.2. Optimisation des Hyperparamètres

Un GridSearchCV sur cinq hyperparamètres (`n_estimators`, `max_depth`, `min_samples_split`, `min_samples_leaf`, `class_weight`) identifie la configuration optimale avec 300 arbres et une profondeur maximale de 20.

5.3. Feature Importance

L'analyse de la Feature Importance révèle que la localisation anatomique et l'âge du patient sont les variables cliniques les plus discriminantes pour la classification des lésions cutanées.

6. Conclusion

Les trois modèles développés offrent des angles d'analyse complémentaires et fournissent ensemble une base solide pour la plateforme de prédiction intégrée présentée dans le chapitre suivant.

Chapitre 6 : Évaluation et Résultats

1. Introduction

Ce chapitre présente l'évaluation finale des trois modèles sur le jeu de test, en utilisant des métriques adaptées au contexte médical et en produisant des visualisations d'explicabilité.

2. Métriques d'Évaluation

2.1. Choix et Justification des Métriques

Dans un contexte médical, le Recall de la classe mélanome est la métrique prioritaire car un faux négatif (mélanome non détecté) expose le patient à un risque vital bien supérieur à celui d'un faux positif.

2.2. Métriques Complémentaires

En complément du Recall mélanome, la F1-Score macro, le ROC-AUC One-vs-Rest et la matrice de confusion 7×7 permettent d'évaluer les performances globales sur l'ensemble des sept classes.

3. Résultats Finaux

3.1. Résultats du CNN from Scratch

Le CNN from scratch obtient une accuracy de 70%, un Recall mélanome de 62% et un ROC-AUC de 0.76, confirmant les limites de l'apprentissage from scratch sur un dataset de 10 000 images.

3.2. Résultats d'EfficientNetB0

EfficientNetB0 atteint une accuracy de 85%, un Recall mélanome de 83% et un ROC-AUC de 0.91, dépassant le seuil critique de 80% fixé comme objectif pour cette métrique prioritaire.

3.3. Résultats du Random Forest

Le Random Forest obtient une accuracy de 73% sur les données tabulaires seules, avec un ROC-AUC de 0.82, illustrant la valeur informative des métadonnées cliniques pour la classification des lésions.

4. Matrices de Confusion

L'analyse des matrices de confusion révèle que les confusions les plus fréquentes concernent les paires mel/nv et bkl/nv, ce qui est cohérent avec la proximité visuelle de ces lésions en dermatoscopie.

5. Grad-CAM — Explicabilité Visuelle

5.1. Principe et Implémentation

L'algorithme Grad-CAM calcule les gradients du score de la classe prédite par rapport aux activations de la dernière couche convolutive d'EfficientNetBo, générant une carte de chaleur superposée à l'image originale.

5.2. Analyse des Heatmaps

Les heatmaps générées montrent que le modèle focalise son attention sur les zones de la lésion présentant une asymétrie de couleur ou de texture, ce qui est cliniquement cohérent avec les critères dermatologiques diagnostiques.

6. Discussion des Résultats

Les résultats obtenus sont compétitifs par rapport aux travaux publiés sur HAM10000 pour un modèle de niveau Licence, et confirment que le Transfer Learning est indispensable pour atteindre des performances médicalement acceptables.

7. Conclusion

L'évaluation confirme qu'EfficientNetBo est le modèle le plus adapté à la production, avec des métriques satisfaisantes pour un outil d'aide au diagnostic préliminaire non certifié.

PARTIE III

Réalisation et Bilan

Développement de la plateforme web, synthèse des travaux et perspectives

Chapitre 7 — Application Web — MelanoScan

Chapitre 8 — Conclusion Générale et Perspectives

Chapitre 7 : Application Web — MelanoScan

1. Introduction

Ce chapitre présente l'architecture et l'implémentation de la plateforme web MelanoScan, qui intègre les modèles IA développés dans une interface utilisateur accessible et intuitive.

2. Architecture Globale de la Plateforme

2.1. Vue d'Ensemble

La plateforme repose sur une architecture découplée composée d'un frontend React/Vite communiquant via API REST avec un backend FastAPI qui orchestre les deux moteurs d'inférence IA.

2.2. Stack Technologique

Le stack technologique combine Python/FastAPI pour le backend IA, React/Vite pour le frontend, PyTorch pour le CNN et Scikit-learn pour le Random Forest, avec une communication asynchrone via JWT.

3. Backend — API FastAPI

3.1. Endpoints Développés

L'API expose six endpoints principaux couvrant l'authentification (/auth), la prédiction tabulaire (/predict/tabular), la prédiction image avec Grad-CAM (/predict/image), et la génération de rapport PDF (/report).

3.2. Intégration des Modèles IA

Les modèles sauvegardés (efficientnet_best.h5, random_forest_best.pkl) sont chargés au démarrage de l'API et exposés via des endpoints dédiés qui gèrent le prétraitement et le post-traitement des requêtes.

4. Frontend — Interface React/Vite

4.1. Formulaire de Saisie Clinique

Le composant ClinicalForm.jsx présente un formulaire guidé collectant l'âge, le sexe et la localisation de la lésion, avec validation en temps réel et retour visuel immédiat à l'utilisateur.

4.2. Module d'Upload d'Image

Le composant ImageUpload.jsx implémente un drag & drop avec prévisualisation de l'image avant envoi, limité aux formats JPG/PNG et à une taille maximale de 10 Mo.

4.3. Affichage des Résultats et Rapport PDF

La page de résultats affiche côte à côte les prédictions du Random Forest et d'EfficientNetBo, avec la heatmap Grad-CAM superposée à l'image et un bouton de téléchargement du rapport PDF.

5. Démonstration et Cas d'Utilisation

Un scénario de démonstration complet est présenté illustrant le flux utilisateur depuis la saisie des données cliniques jusqu'à la consultation du rapport de prédiction téléchargeable.

6. Conclusion

La plateforme MelanoScan constitue une intégration réussie des modèles IA dans une interface web complète, offrant une expérience utilisateur fluide tout en préservant la rigueur technique des prédictions.

Chapitre 8 : Conclusion Générale et Perspectives

1. Synthèse des Travaux Réalisés

Ce projet a permis de concevoir et développer une plateforme multimodale de détection du mélanome intégrant trois modèles IA complémentaires et une interface web complète, couvrant l'ensemble du cycle de développement IA.

2. Réponse à la Problématique

La problématique posée en introduction — concevoir une architecture IA multimodale et explicable pour assister le diagnostic du mélanome — a été adressée par la combinaison d'EfficientNetBo, du Random Forest et de Grad-CAM.

3. Apports Scientifiques et Techniques

L'apport principal de ce projet réside dans la comparaison quantitative rigoureuse entre CNN from scratch et Transfer Learning sur HAM10000, produisant des résultats reproductibles et documentés servant de référence pour de futurs travaux.

4. Limites du Projet

Les principales limitations identifiées sont le biais démographique du dataset HAM10000, l'absence de validation clinique externe, et la non-intégration d'une fusion multimodale des deux modalités de prédiction.

5. Perspectives d'Amélioration

5.1. Fusion Multimodale

Une perspective majeure consiste à implémenter une fusion late (weighted average) ou une architecture d'attention combinant les prédictions CNN et Random Forest pour obtenir une prédiction unifiée plus robuste.

5.2. Diversification du Dataset

L'enrichissement du dataset avec des images de phototypes Fitzpatrick IV à VI permettrait de réduire le biais démographique et d'améliorer la capacité de généralisation des modèles sur des populations plus diversifiées.

5.3. Déploiement et Certification

Le déploiement de la plateforme sur un serveur cloud et son évaluation dans un cadre clinique supervisé constitue une perspective à long terme nécessitant une certification médicale préalable.

6. Conclusion Finale

Ce projet de fin d'études a représenté une expérience formatrice complète, alliant la rigueur scientifique de l'évaluation de modèles IA au défi technique du développement d'une application web fonctionnelle. Les compétences acquises en Deep Learning, en Machine Learning et en développement fullstack constituent une base solide pour la suite de notre parcours professionnel.